

Informe Técnico – Primera Entrega

Conceptualización del problema

En un entorno empresarial colombiano marcado por la hipercompetencia, la saturación de oferta y la transformación digital, la capacidad de una organización para entender y anticiparse a las necesidades del cliente se ha vuelto una necesidad estratégica. El problema central que se aborda en este reto es la búsqueda de una solución automatizada para suplir la limitada capacidad de las empresas para personalizar la experiencia del consumidor. Esta problemática compromete no solo la satisfacción y fidelización del cliente, sino también el aprovechamiento pleno del valor de los datos transaccionales acumulados, generando ineficiencias operativas y oportunidades de venta desaprovechadas. En este contexto, la ausencia de un enfoque inteligente en la recomendación de productos impide la consolidación de relaciones duraderas con los usuarios y dificulta la optimización de portafolios en función de patrones reales de comportamiento y alineación estratégica.

La problemática tratada también trasciende el ámbito tecnológico para situarse en una intersección entre la analítica de datos, estrategia comercial y diseño de experiencias. Por ende, se plantea la necesidad de desarrollar un sistema robusto que articule capacidades de *machine learning* con objetivos de negocio claramente definidos: incrementar la conversión de ventas, facilitar la labor de los asesores en punto de venta y generar *insights* accionables para la toma de decisiones. La solución debe ser capaz de absorber, interpretar y capitalizar datos heterogéneos de distintas fuentes (transacciones, cotizaciones y ventas B2B), para derivar recomendaciones personalizadas que no solo respondan al historial del cliente, sino que estén alineadas con el portafolio estratégico de la compañía. En suma, se trata de superar las limitaciones actuales de la gestión comercial a través de un modelo de recomendación inteligente que funcione como catalizador de valor integral para el negocio.

Análisis descriptivo

Base Transaccional B2C (base 1 transaccional)

Para comenzar el desarrollo del proyecto, se llevó a cabo un análisis exploratorio detallado utilizando la base de datos B2C, compuesta por 2.099.836 registros y 18 variables explicativas. Esta base contiene información clave sobre el comportamiento de compra del consumidor final, incluyendo datos como el tipo de producto, su categoría y subcategoría, la fecha de transacción, el valor total de la compra y su alineación con el portafolio estratégico B2C.

La calidad de los datos fue satisfactoria en general. No se detectaron registros duplicados y el porcentaje de datos faltantes no fue superior al 2% en la variable precio y al 0.008% en la variable zona, estos problemas de completitud fueron resueltos eliminando dichos registros ya que la ausencia de esas dos variables los convierte en información no relevante para el proyecto. Con respecto a la preparación de los datos, la variable “fecha_factura” fue transformada correctamente al formato *datetime*, lo que facilita la exploración de tendencias temporales y la identificación de patrones estacionales.

En cuanto a las variables numéricas, la variable “valor” presentó una distribución claramente sesgada hacia la derecha. El 75% de las transacciones registran valores iguales o inferiores a aproximadamente 37 unidades monetarias, lo que indica una alta concentración de compras de bajo valor. Sin embargo, se observan valores extremos que alcanzan hasta 56,876 unidades, lo cual sugiere la existencia de adquisiciones puntuales de alto valor, posiblemente relacionadas con productos premium, compras por volumen o campañas especiales. La mediana se sitúa en 13.32 unidades, reflejando una diferencia significativa frente al valor máximo y reafirmando el sesgo positivo. Por otro lado, la variable “edad” muestra una distribución relativamente simétrica, con una media de aproximadamente 41.9 años y una mediana cercana (43 años). Sin embargo, hay una altísima presencia de compradores al inicio de sus 30, estos podrían representar a los clientes que están independizando y por ende realizan muchas compras para la adecuación de su nuevo hogar.





Ilustración 1 Histogramas de frecuencia de edad

La variable “alineación con portafolio estratégico” mostró una alta dispersión, con valores entre -24,187 y 4,162. Aunque la media (3.95) y la mediana (1.41) indican una leve alineación positiva en la mayoría de las transacciones, la presencia de valores negativos y extremos sugiere comportamientos comerciales dispares. Esto resalta la necesidad de guiar a los clientes hacia productos más

alineados con la estrategia de la compañía.


El análisis de correlación reveló una relación moderada y positiva entre el “valor” y la “alineación con portafolio estratégico” ($r = 0.53$), lo que sugiere que las transacciones de mayor valor tienden a estar más alineadas con los objetivos estratégicos de la compañía. También se observa una correlación moderada entre “valor” y “cantidad” ($r = 0.51$),

indicando que el monto total está fuertemente influenciado por el volumen de productos adquiridos.



En general, el resto de las variables presentan correlaciones débiles o casi nulas entre sí, lo que indica una baja multicolinealidad y una relativa independencia entre los atributos.

En lo que respecta a las variables categóricas, se evidencia una fuerte concentración de transacciones en un número reducido de municipios y zonas. El municipio de Curití representa más del 27% del total de transacciones, seguido por Natagaima y Villanueva. A nivel de zona, Santander domina ampliamente con más de 700 mil registros, seguido de Tolima y Antioquia. Esta concentración geográfica plantea oportunidades para diversificar la cobertura comercial y fortalecer estrategias locales en zonas con menor participación.



En cuanto a los puntos de venta y asesores, los cinco principales puntos concentran una proporción significativa del volumen total, con “punto_venta_7” a la cabeza (132,386 transacciones). De manera similar, algunos asesores como “asesor_137” y “asesor_7” superan las 14 mil ventas, mientras que más de 300 asesores tienen apenas una transacción registrada, lo que refleja una distribución altamente desigual en el desempeño comercial.




Ilustración 4 Histograma de cluster

Respecto a los clústeres, más del 80% de las ventas están concentradas en “cluster_tienda_3” y “cluster_tienda_2”, lo cual indica una segmentación de mercado dominada por unos pocos perfiles de tienda. A nivel de producto, se identificaron más de 7,200 referencias únicas, aunque el producto más vendido (“producto_49”) representa apenas el 2.56% del total, lo que indica una alta dispersión en las preferencias del

consumidor. Este patrón se mantiene a nivel de subcategorías y categorías, con más de 100 subcategorías y 27 categorías, pero una fuerte concentración en las más populares como “subcategoria_5” y “categoria_3”.

En cuanto a las categorías macro, cinco agrupan la totalidad de las transacciones, destacándose “categoria_macro_2” con más de 1.3 millones de registros (62% del total), seguida por “categoria_macro_4” y “categoria_macro_1”. Finalmente, la variable “color” también muestra un patrón concentrado: más del 47% de las referencias no tienen color identificado, y entre las restantes predominan tonos neutros como gris, blanco y beige. Estos hallazgos destacan la necesidad de mejorar la calidad del dato en ciertas dimensiones y de adoptar estrategias de diversificación que reduzcan la dependencia de territorios, asesores y productos específicos.

Base de Cotizaciones B2C (base_2_cotizaciones)

Para comprender la dinámica de cotización del segmento B2C, se llevó a cabo un análisis exploratorio exhaustivo sobre la base de datos proporcionada, la cual contiene 180.387 registros distribuidos en 11 variables explicativas. Esta base refleja el comportamiento de los clientes en procesos de solicitud de información o intención de compra, permitiendo identificar patrones de interés sobre el portafolio comercial y la interacción con los productos ofrecidos.

Con respecto a la calidad de datos se encontró que la base de datos estaba completa, sin embargo, se evidenció un problema de duplicados que fue resuelto eliminándolos. La consistencia de las variables numéricas y categóricas, junto con la validez de estos fueron coherentes con el contexto y los datos. Los datos de fecha no estaba en formato datetime lo que podía perjudicar el manejo de los mismo y por ende se cambió al formato esperado.

El análisis de las variables numéricas en las cotizaciones B2C muestra un comportamiento altamente asimétrico y disperso. El valor total (valor) tiene una media de 36,9 pero un

máximo superior a 366.000, evidenciando outliers significativos y un sesgo positivo. El 75% de los registros están por debajo de 27,6, lo que indica un mercado dominado por productos de bajo costo, aunque existen casos excepcionales de productos premium.

La variable cantidad presenta una alta dispersión (std = 1.128) y un valor máximo extremo de 438.000 unidades, lo cual también sugiere la existencia de registros atípicos o compras mayoristas aisladas.




Ilustración 5 Histograma de distribución de estado de cotización

Este patrón sugiere un proceso comercial con alta efectividad de conversión desde la etapa de cotización, aunque también podría reflejar una sobre clasificación automática como "ganada" si no hay actualización posterior.

En cuanto a correlaciones, valor se relaciona débilmente con cantidad ($r = 0.10$) y precio ($r = 0.056$), lo cual es esperado ya que $\text{valor} = \text{cantidad} * \text{precio}$, pero las correlaciones bajas indican alta variabilidad en estas relaciones. El resto de las variables no muestra correlaciones relevantes con los datos económicos y operativos, y pueden considerarse identificadores sin valor predictivo.

Este comportamiento refuerza la necesidad de limpieza de outliers, especialmente en cantidad, y de modelar considerando la alta varianza y fragmentación del mercado.

En cuanto a las variables categóricas, específicamente "estado_cotizacion", se observa una clara predominancia de cotizaciones ganadas, que representan cerca del 77% del total. Le siguen en frecuencia las cotizaciones expiradas, mientras que las abiertas y perdidas tienen una participación marginal y muy similar entre sí.




Ilustración 6 Correlación entre las variables numéricas del cotizaciones

Base Transaccional B2B (base 3 transaccional b2b)

Para comprender la dinámica comercial del segmento B2B, se realizó un análisis exploratorio detallado sobre la base de datos brindada, la cual contiene 25,866 transacciones con 10 variables explicativas. Esta base representa información transaccional relevante, destacando aspectos clave como el tipo de producto adquirido, su categoría y subcategoría, la fecha de compra, el valor total de la transacción y su alineación con el portafolio estratégico B2B. Es importante mencionar que se evaluó la calidad de los datos, destacando que no se identificaron valores nulos ni registros duplicados. Esto facilitó un análisis directo, sin necesidad de limpieza adicional. La variable “fecha_factura” fue correctamente transformada al formato *datetime*, permitiendo futuros análisis temporales como identificación de estacionalidades o tendencias comerciales.




Ilustración 7 Histograma y boxplot de "valor_total"

Respecto a las variables numéricas, la variable “valor_total” mostró una distribución claramente sesgada hacia la derecha, con numerosos valores atípicos, como se evidencia en los histogramas y *boxplots* realizados. El 75% de las transacciones están por debajo de aproximadamente 2,200 unidades

monetarias, destacando una concentración de valores bajos a medios, mientras que algunos valores extremadamente altos alcanzan hasta cerca de 68,750 unidades monetarias. Estos valores atípicos podrían estar asociados a transacciones puntuales de alto valor, posiblemente correspondientes a productos premium o adquisiciones de clientes corporativos clave.

La variable “alineación con portafolio estratégico B2B” mostró una distribución altamente concentrada alrededor de cero con una desviación estándar muy baja (0.000155), indicando que la mayoría de las transacciones están relativamente cercanas




Ilustración 8 Histograma y boxplot de "alineación con portafolio estratégico B2B"

a un valor neutro. Sin embargo, la media (0.000294) y el valor máximo observado (0.000654) son tan bajos que, desde un punto de vista práctico, se interpretan como una baja alineación con el portafolio estratégico. Esto implica que muchas de las compras realizadas, aunque no necesariamente negativas, no parecen ser las más efectivas ni acordes con la estrategia definida por la empresa.

La presencia adicional de valores negativos, llegando hasta -0.008, enfatiza aún más la existencia de transacciones que claramente se alejan del enfoque estratégico deseado. En términos prácticos, esto representa una importante oportunidad para reevaluar y ajustar las estrategias comerciales, asegurando que las futuras transacciones prioricen productos con mayor valor estratégico para la compañía, optimizando así el uso de recursos y aumentando la efectividad comercial general. No obstante, se entiende que, al tratarse del segmento B2B, existe una limitación inherente al control directo sobre los productos que terceros comercializan. Por ello, se podría pensar en implementar campañas dirigidas específicamente a incentivar o patrocinar productos más alineados con la estrategia de la

empresa, motivando así a los aliados comerciales a promover aquellas referencias que mejor se ajustan a los objetivos estratégicos corporativos.

En el análisis de correlación, se identificó una correlación negativa débil ($r = -0.13$) entre “valor_total” y “alineación con portafolio estratégico b2b”. Esta asociación, aunque pequeña, indica una leve tendencia en que transacciones de mayor valor podrían estar menos alineadas con el portafolio estratégico. Esto podría significar que los clientes con transacciones más altas podrían estar

adquiriendo productos menos prioritarios desde la perspectiva estratégica de la empresa. Tal hallazgo, aunque limitado en magnitud, ofrece información valiosa para futuras revisiones estratégicas y comerciales que permitan aumentar la alineación estratégica de las transacciones más significativas en términos monetarios.




Ilustración 9 Gráfica de correlación de las variables numéricas B2B

Desde el punto de vista categórico, se observa una concentración significativa en pocos actores. A nivel de clientes B2B, más del 50% de las transacciones están concentradas en el cliente B2B_03, seguido por B2B_02 y B2B_01. Esto implica una fuerte dependencia comercial en unos pocos aliados estratégicos. Por municipios, destaca Fusagasugá con más del 62% de las transacciones, seguido por Villa de Leyva y Madrid. Un pequeño porcentaje (1.5%) tiene registros con municipio desconocido ("#"), lo cual debería revisarse si se desea realizar análisis geográficos más precisos. En cuanto a zonas, Cundinamarca representa el 71% de las ventas, seguida de Boyacá con un 27%.




Ilustración 10 Distribución de los compradores B2B

En cuanto a las categorías de productos, tanto a nivel macro como específico, la distribución también es bastante desigual. Las cinco principales categorías macro concentran más del 78% del total de transacciones, siendo la categoría "cat_b2b_macro_1" la más destacada con el 22.3%. A nivel más granular, se identifican más de 130 subcategorías y más de 2,500 productos únicos, aunque nuevamente, una minoría de ellos acumula la mayoría del volumen de transacciones. Por ejemplo, el producto más vendido apenas representa el 1.11% del total.

Los hallazgos revelan una estructura de ventas altamente concentrada, tanto en un número reducido de clientes como en un subconjunto limitado del portafolio de productos, lo que resalta la necesidad de adoptar estrategias segmentadas más precisas. Una vía clave para abordar esta situación es diversificar el portafolio transaccional, impulsar la rotación de productos estratégicamente alineados y disminuir la dependencia comercial de un grupo tan acotado de clientes y referencias. No obstante, considerando que en el modelo B2B la empresa no ejerce control directo sobre las decisiones de compra de sus aliados, la implementación de un sistema de recomendación debe enfocarse en una lógica de acompañamiento inteligente. Aprovechando los datos detallados disponibles tanto del canal B2B como del B2C —incluyendo información geográfica como municipios y departamentos— es posible identificar patrones de consumo específicos por zona. Con base en esta evidencia, el sistema podrá sugerir al aliado comercial productos con alta demanda en su región, motivándolo a incorporar dichas referencias para responder mejor a las necesidades locales. Así, lejos de imponer decisiones, el modelo actúa como un facilitador estratégico que orienta al cliente hacia decisiones comerciales más informadas y alineadas con los objetivos de la compañía.

Enriquecimiento de la base de datos

En el contexto de este reto, donde se busca desarrollar un modelo de recomendación inteligente capaz de personalizar la oferta de productos y mejorar la experiencia del cliente, se identificó la necesidad de complementar las bases de datos transaccionales con información adicional que permitiera captar mejor el contexto y las necesidades de los consumidores. Aunque inicialmente se evaluó la posibilidad de incorporar variables individuales como género, ocupación o preferencias personales, las bases disponibles — particularmente la B2C, que cuenta con el mayor nivel de granularidad— no incluyen este tipo de atributos. Si bien contiene datos como edad, municipio, punto de venta y producto adquirido, estos no son suficientes para capturar completamente los factores que inciden en la decisión de compra. Frente a esta limitación, se optó por enriquecer la información con variables externas de carácter demográfico, que pudieran contextualizar la demanda a nivel territorial. Se incorporaron así datos agregados por municipio y/o departamento, como porcentaje urbano, nivel de empleabilidad y otras condiciones socioeconómicas.

Este enfoque permite al modelo de recomendación ir más allá de los historiales de compra y considerar factores que inciden en las necesidades reales de los consumidores según su entorno. En lugar de imponer decisiones dentro del canal B2B —donde el control directo sobre lo que el tercero decide comprar es limitado—, el sistema podrá sugerir productos relevantes basados en comportamientos observados en la misma zona geográfica. Por ejemplo, si en determinado municipio los datos B2C muestran alta demanda de un producto específico, se puede recomendar al cliente B2B que lo incluya en su portafolio para satisfacer la demanda local.

Con incluir esta información extra, se busca que el modelo no solo mejore la conversión de ventas y facilite el trabajo de los asesores comerciales, sino que también funcione como una herramienta estratégica para alinear las decisiones comerciales con los objetivos de negocio, maximizando así el valor de los datos y la eficiencia operativa en un entorno altamente competitivo.

Base Transaccional B2C (base 1 transaccional)

Con el fin de enriquecer aún más la base de datos y aumentar el poder predictivo del modelo de recomendación, se generaron una serie de variables a partir de los datos transaccionales del canal B2C. Estas nuevas columnas fueron construidas con base en el comportamiento histórico de cada cliente y buscan capturar distintos aspectos de su patrón de compra. A continuación, se describen cada una de ellas y su relevancia en el contexto del modelo:

1. Total de productos comprados (“total_productos”): Esta variable representa la cantidad total de unidades adquiridas por cada cliente a lo largo del período analizado. Es un buen

indicador del volumen de consumo individual, y permite diferenciar entre compradores ocasionales y clientes recurrentes con alta actividad.

2. Total gastado (“total_gasto”): Mide la suma total de dinero que cada cliente ha invertido en sus compras. Su inclusión permite identificar a los clientes de mayor valor, esenciales para estrategias de fidelización y recomendaciones de productos premium o de mayor rentabilidad.

3. Precio promedio por cliente (“precio_promedio”): Calculado como el gasto total dividido por el número total de unidades compradas, este indicador ayuda a estimar el rango de precios en el que cada cliente suele consumir. Es clave para ajustar recomendaciones a la capacidad de gasto real de cada usuario.

4. Número de pedidos distintos (“num_pedidos”): Refleja la frecuencia con la que un cliente ha realizado compras. Un mayor número de pedidos puede ser interpretado como una mayor fidelidad o hábito de consumo más frecuente, útil para segmentar y priorizar campañas personalizadas.

5. Ticket promedio (“ticket_promedio”): Indica el valor promedio de cada pedido realizado. Esta métrica ayuda a clasificar a los clientes según su nivel de inversión por transacción y a personalizar recomendaciones en función de su comportamiento de gasto en cada visita.

6. Cantidad promedio por pedido (“cantidad_promedio”): Permite conocer cuántos productos, en promedio, compra un cliente por pedido. Ayuda a entender la profundidad de compra y la posible complementariedad entre categorías o subcategorías de producto.

7. Número de categorías diferentes compradas (“categorias_diferentes”): Este atributo refleja la diversidad en el consumo del cliente, es decir, si suele comprar dentro de una categoría específica o si explora varias. Es útil para sugerir productos complementarios o introducir nuevas categorías que aún no ha explorado.

Además de las variables generadas internamente a partir de los datos transaccionales, se incorporaron **variables externas provenientes de fuentes oficiales como el DANE**, con el fin de representar el contexto socioeconómico y demográfico de los municipios o departamentos donde se realizaron las compras:

8. Edad promedio (“edad_promedio”) e ingreso laboral promedio (“ingreso_laboral_promedio”): Estas variables brindan un panorama general del perfil demográfico del territorio. La edad promedio puede orientar el tipo de productos recomendados, mientras que el ingreso laboral permite ajustar las sugerencias en función de la capacidad adquisitiva de la población local.

9. Porcentaje urbano (“porcentaje_urbano”): Este dato ayuda a identificar el grado de urbanización de la zona, lo cual puede estar relacionado con el tipo de productos más demandados (por ejemplo, productos de alta rotación en áreas urbanas versus productos básicos en zonas rurales).

10. Índice de pobreza multidimensional (“IPUG”) y coeficiente de GINI (“GINI”): Ambas variables son indicadores del nivel de desigualdad y pobreza del territorio. Su inclusión permite matizar las recomendaciones con sensibilidad socioeconómica, evitando sugerencias poco realistas en contextos donde el poder adquisitivo es limitado.

11. Total de edificaciones en obra: Se incorporó el total de edificaciones en obra, una variable extraída del censo nacional de edificaciones en construcción. Esta información resulta particularmente útil para detectar zonas en crecimiento o expansión urbanística, donde es esperable que se generen nuevas demandas de productos. En contextos de desarrollo urbano, aumenta la necesidad de artículos para el hogar, materiales de construcción, mobiliario y otros productos relacionados que pueden estar disponibles dentro del catálogo actual de la empresa. De este modo, la variable permite anticiparse a movimientos del mercado local y orientar estratégicamente la oferta hacia zonas con mayor potencial de consumo futuro.

La incorporación de estas variables permite al modelo de recomendación no solo entender al cliente desde una perspectiva transaccional, sino también desde su contexto social, económico y territorial. Esto abre la puerta a una personalización mucho más profunda, sensible y estratégicamente alineada con las necesidades reales del consumidor y con los objetivos comerciales de la compañía.

Base Transaccional B2B (base 3 transaccional b2b)

En el marco del desarrollo del modelo de recomendación, y con el objetivo de enriquecer la base transaccional del canal B2B, se incorporaron variables externas provenientes de fuentes oficiales como el DANE. Dado que en el canal B2B la compañía no tiene control directo sobre lo que el aliado comercial decide adquirir, estas nuevas variables buscan contextualizar el entorno económico y urbano en el que operan dichos aliados, permitiendo generar recomendaciones más informadas y relevantes según la zona geográfica.

A diferencia del canal B2C, donde se dispone de información más detallada por cliente, en el B2B el enfoque de enriquecimiento se basa en datos agregados a nivel municipal y departamental. Estas variables permiten representar el dinamismo económico y urbano del territorio, aspectos clave para anticiparse a las necesidades de los consumidores finales a quienes el tercero vende. A continuación, se detallan las nuevas columnas incluidas:

1. Total de edificaciones en obra: Representa el número total de proyectos de construcción en curso dentro del municipio. Esta variable permite identificar zonas en expansión urbanística, donde puede esperarse un aumento en la demanda de productos relacionados con el hogar, remodelación, construcción, decoración y otras categorías estratégicas para la compañía.
2. Promedio de edificaciones por manzana: Esta métrica ofrece una perspectiva más localizada del dinamismo urbano, indicando la intensidad de la actividad constructiva en relación con la densidad territorial. Es útil para detectar microzonas con mayor potencial de crecimiento.
3. Tasa de edificaciones por manzana (estandarizada): Aporta una normalización territorial de la actividad constructiva, permitiendo comparar de manera más justa entre municipios de diferente tamaño. Una alta tasa puede sugerir áreas de inversión y desarrollo acelerado, lo que puede justificar un enfoque comercial más activo.
4. Tasa de edificaciones por habitante (estandarizada): Mide la cantidad de edificaciones activas en relación con la población del municipio. Una alta relación puede señalar una oportunidad de capturar nuevos clientes, dada la disponibilidad de nueva infraestructura y potenciales hogares o comercios en formación.
5. Total de unidades económicas activas: Esta variable refleja el número de establecimientos económicos registrados y operativos dentro del territorio. Es clave para entender el entorno competitivo y la densidad de actividad comercial, permitiendo enfocar esfuerzos en zonas con alta concentración de negocios y mayor probabilidad de transacciones recurrentes.
6. Participación económica del municipio: Indica el peso relativo del municipio dentro del total nacional de unidades económicas. Esta variable permite priorizar estratégicamente las zonas que, aunque no necesariamente con mayor número de edificaciones, sí representan polos importantes de actividad empresarial.

La integración de estas variables en el canal B2B permite al modelo de recomendación adaptar sus sugerencias en función del entorno en el que se encuentra el cliente empresarial. En lugar de imponer productos, se pueden sugerir aquellos con mayor potencial de demanda a nivel local, basándose en evidencia real del dinamismo urbano y económico. Este enfoque no solo mejora la relevancia de las recomendaciones, sino que también fortalece la relación con los aliados comerciales, al ofrecerles propuestas alineadas con el comportamiento de consumo de su zona, lo que podría traducirse en mayor rotación de inventario, mejor experiencia del consumidor final y mayor fidelización al canal.

Principales hallazgos

En el canal B2B, se exploró la posibilidad de identificar patrones de comportamiento mediante técnicas de agrupamiento, con el objetivo de segmentar a los aliados comerciales según características transaccionales comunes. Inicialmente se aplicó el algoritmo KMeans, una técnica de clustering ampliamente utilizada que agrupa observaciones en función de su cercanía a centros de masa (centroides) optimizados. Sin embargo, al evaluar la calidad de la segmentación obtenida, se observó un coeficiente de silueta de apenas 0.13, lo que sugiere que las agrupaciones generadas no eran claras ni coherentes, es decir, los puntos dentro de los *clusters* estaban poco cohesionados y poco separados entre sí.




Ilustración 11 Distribución de los Meta-Cluster construidos

cual indica una segmentación mucho más definida. No obstante, DBSCAN generó un número excesivo de clusters —1,178 grupos— muchos de los cuales contenían muy pocos elementos (algunos con tan solo entre 2 y 10 observaciones), lo que dificultaba extraer conclusiones prácticas o estrategias comerciales sólidas a partir de ellos.

Para superar esta limitación, se implementó una estrategia de realizar agrupación de los grupos encontrados. A partir de los *clusters* generados por DBSCAN (excluyendo los puntos identificados como *outliers*), se calcularon los centroides de cada grupo con base en sus variables numéricas. Posteriormente, se aplicó nuevamente KMeans, esta vez sobre estos centroides, con el fin de consolidar los *clusters* en grupos más interpretables y estratégicamente útiles. Esta técnica permitió sintetizar la gran cantidad de *clusters* originales en 10 "meta-clusters", agrupando a los aliados comerciales en subconjuntos de mayor tamaño y coherencia.

Ante este bajo desempeño, se optó por explorar otro enfoque: DBSCAN (Density-Based Spatial Clustering of Applications with Noise). Este algoritmo permite descubrir grupos de densidad similar sin requerir especificar el número de *clusters* previamente, y es especialmente útil cuando los datos contienen ruido o estructuras no esféricas. Los resultados fueron prometedores en términos de calidad: se alcanzó un coeficiente de silueta de 0.78, lo

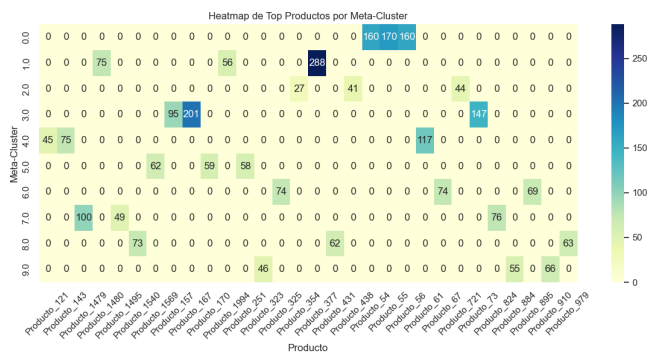


Ilustración 12 Distribución de productos de los meta-clusters




Ilustración 13 Gráfica PCA de los clusters

El resultado fue una estructura más manejable y valiosa desde el punto de vista analítico. lo que permite distinguir perfiles de clientes B2B con diferentes patrones de compra. A pesar de no contar con descripciones detalladas de los productos, se asumió que aquellos con numeraciones similares podrían pertenecer a una misma línea o tipo. Bajo esta premisa, se destacan tres meta-clusters que presentan patrones de compra claros y diferenciados:

- **Meta-Cluster 0 (8,416 registros):** Este es el grupo más numeroso del análisis y se caracteriza por una fuerte concentración en tres productos consecutivos: Producto_55, Producto_54 y Producto_56, cada uno con más de 160 unidades vendidas. Esta homogeneidad sugiere un perfil de cliente altamente especializado, posiblemente vinculado a una sola línea del portafolio. Sin embargo, a pesar de su tamaño, este grupo presenta uno de los valores promedio de compra más bajos. Esto sugiere que, aunque los clientes realizan muchas compras, lo hacen sobre productos de bajo precio. En consecuencia, se trata de un grupo con alto volumen, pero bajo valor promedio, lo cual lo convierte en un segmento ideal para estrategias que busquen aumentar el valor por transacción.
- **Meta-Cluster 1 (1,533 registros):** Este grupo muestra una marcada preferencia por Producto_377, con 288 unidades vendidas, muy por encima del resto. También destacan Producto_1480 y Producto_1994, aunque en menor proporción. Este patrón sugiere una alta dependencia de un producto clave, probablemente vinculado a una necesidad operativa específica. El valor promedio de compra en este grupo se encuentra en un rango medio, lo que indica que, además de ser consistentes en sus elecciones, los clientes realizan compras de valor moderado. Dado su comportamiento focalizado y estable, este meta-cluster representa un nicho estratégico que podría beneficiarse de recomendaciones complementarias, programas de fidelización o condiciones comerciales especiales para fortalecer la relación y fomentar la retención.

- **Meta-Cluster 3 (2,457 registros):** Este grupo se distingue por una mayor diversidad de productos con alto volumen de ventas: Producto_167 (201 unidades), Producto_73 (147) y Producto_157 (95). Este patrón sugiere un comportamiento de compra consistente y centrado en volumen, típico de revendedores o distribuidores en mercados con alta rotación. Sin embargo, a pesar de su tamaño y variedad, el grupo presenta uno de los valores promedio de compra más bajos. Esto indica que adquieren productos económicos en grandes cantidades, lo que refuerza su perfil de clientes mayoristas o de bajo margen. Para este segmento, las estrategias comerciales deberían enfocarse más en garantizar disponibilidad, eficiencia logística y estabilidad en precios.




Ilustración 14 Valor total promedio de los clusters

Cabe mencionar que también se intentó replicar el proceso de agrupamiento sobre la base transaccional B2C, con el fin de identificar segmentos de clientes individuales y sus patrones de consumo. No obstante, debido al tamaño y granularidad de dicha base —que contiene un volumen significativamente mayor de registros y variables codificadas—, el proceso resultó inviable desde el punto de vista computacional. Al aplicar técnicas como KMeans o DBSCAN sobre el conjunto completo, los modelos arrojaban errores relacionados con la dimensionalidad y la capacidad de procesamiento de la máquina, imposibilitando la convergencia o ejecución exitosa del algoritmo. Esto se debe a que, en datasets de alta dimensión, los algoritmos de clustering requieren recursos intensivos y pueden volverse ineficientes o inestables. Por esta razón, se priorizó el análisis de agrupamientos en el canal B2B, donde la estructura de datos era más manejable y permitía obtener resultados útiles y accionables en términos comerciales.

Metodología para implementar

Con base en el análisis exploratorio exhaustivo, el enriquecimiento multifuente de las bases de datos y la segmentación obtenida a través de modelos de agrupamiento, se plantean múltiples alternativas metodológicas para el desarrollo de un sistema de recomendación robusto, escalable y estratégicamente alineado.

1. Recomendación basada en contenido (Content-Based Filtering)

Este enfoque se fundamenta en el análisis del perfil individual del cliente y las características estructurales del producto, sin requerir información sobre el comportamiento de otros usuarios. Esto lo convierte en una alternativa ideal para escenarios donde existen clientes

con historiales limitados o para mantener independencia entre segmentos. En el caso del canal B2C, la granularidad de los datos disponibles como: edad, ticket promedio, número de pedidos o comportamiento por zona, permite construir perfiles detallados y representativos que capturan de forma precisa los patrones de consumo de cada cliente.

Para su implementación, se construirían vectores de características por cliente, que agregan información clave sobre su historial transaccional: categorías compradas, gasto total, precio promedio por unidad, cantidad promedio por pedido, entre otros. Paralelamente, se elaborarían vectores para cada producto, utilizando atributos como categoría macro y específica, subcategoría, precio, alineación estratégica, color y rotación observada en zonas similares. Una vez estructurados ambos espacios vectoriales, se calcula la similitud entre clientes y productos usando métricas como el coseno de similitud o la distancia euclídea. El resultado es un ranking de productos que presentan mayor afinidad con el perfil del cliente.

Este enfoque no solo permite recomendaciones personalizadas con alta precisión, sino que también tiene un modelo altamente interpretable. Es posible explicar por qué se recomienda un producto concreto (por ejemplo, porque pertenece a una categoría frecuentemente adquirida o se encuentra dentro del rango de gasto promedio del cliente). Además, la lógica basada en atributos facilita incorporar filtros o reglas adicionales, como priorizar productos estratégicamente alineados o disponibles en zonas geográficas específicas.

En el contexto de Corona, esta metodología resulta especialmente útil para atender la **diversidad de perfiles** del canal B2C, ya que se adapta dinámicamente al comportamiento de cada cliente sin necesidad de compararlo con otros. Asimismo, su estructura modular permite integrar futuras variables enriquecidas o contextuales sin rediseñar por completo el sistema de recomendación.

2. Sistemas híbridos (Hybrid Recommender Systems)

Una segunda línea metodológica robusta y flexible consiste en la implementación de sistemas híbridos de recomendación, los cuales combinan técnicas de recomendación basada en contenido con reglas de negocio y criterios contextuales.

Este enfoque permite capturar no solo las preferencias individuales del cliente, derivadas de su historial transaccional, sino también incorporar factores estratégicos de la empresa y condiciones socioeconómicas del entorno. El sistema híbrido parte de los vectores de perfil cliente-producto construidos previamente, a los cuales se les aplican filtros o ponderaciones adicionales. Por ejemplo, puede priorizar productos con alta rotación en zonas con características similares (utilizando variables como IPUG o GINI) o con mayor alineación

estratégica, ajustando así la recomendación no solo a lo que el cliente ha comprado, sino a lo que resulta comercialmente deseable y geográficamente relevante.

El desarrollo de este sistema parte de la construcción de vectores de perfil para cada cliente, alimentados con variables calculadas. Paralelamente, cada producto es representado también mediante un vector que resume sus atributos. A partir de estos vectores, se calcula una métrica de similitud (como coseno de similitud) entre cada cliente y los productos disponibles en el catálogo, de forma similar al primer modelo planteado.

Una vez obtenida la similitud básica, se introducen filtros y ponderaciones estratégicas que ajustan la recomendación para priorizar productos que no solo son relevantes desde la perspectiva individual del cliente, sino que también están alineados con los intereses y reglas de negocio de Corona. Por ejemplo, se pueden penalizar productos con baja alineación estratégica, o bien aumentar el puntaje de productos que muestran alta conversión en clústeres similares.

En el caso del canal B2B, este enfoque adquiere un valor adicional. Se puede incluir una relación intermedia donde la empresa busca influir en lo que sus aliados comerciales promueven y venden. A partir de los resultados en B2C dentro de una zona determinada y los recomienda al cliente B2B como oportunidad de venta basada en evidencia empírica. Así, el modelo no se limita a replicar patrones del pasado, sino que actúa como un asesor virtual que guía las decisiones comerciales de los aliados en función del contexto.

3. Modelos basados en técnicas de aprendizaje supervisado (Supervised Machine Learning Models)

Por otro lado, una tercera alternativa metodológica contempla el uso de modelos de aprendizaje supervisado como herramienta central para el sistema de recomendación. Bajo este enfoque, el problema se plantea como una tarea de predicción: dado un cliente y un producto, se estima la probabilidad de que ocurra una compra. Para ello, se entrena un modelo con algoritmos como XGBoost, LightGBM o Random Forest, utilizando como variables predictoras un conjunto integral de información que se ha venido puliendo y fue descrito en los literales anteriores. La variable objetivo sería una etiqueta binaria que indicaría si el cliente ha comprado o no un determinado producto. Los algoritmos mencionados son adecuados para este problema debido a su eficiencia, capacidad para manejar grandes volúmenes de datos y su facilidad para interpretar resultados mediante medidas de importancia de variables.

Una vez entrenado, el modelo puede aplicarse a todo el universo de combinaciones posibles entre clientes y productos no comprados, generando así una probabilidad de compra

estimada para cada caso. Con base en estas probabilidades, se construyen rankings personalizados de productos para cada cliente, priorizando aquellos con mayor probabilidad de conversión.

Esta metodología ofrece una alta flexibilidad estratégica, ya que el modelo puede ajustarse según distintos objetivos de negocio: maximizar la conversión, que se traduzca en el aumento de ventas. Además, permite establecer filtros como rangos de precio adecuados, convirtiéndola en una metodología personalizable y versátil.

Bibliografía

DANE - Empleo y desempleo. (s.f). Gov.co. Recuperado el 7 de abril de 2025, de <https://www.dane.gov.co/index.php/estadisticas-por-tema/mercado-laboral/empleo-y-desempleo>

Gran Encuesta Integrada de Hogares - GEIH - 2024. (s.f). Gov.co. Recuperado de <https://microdatos.dane.gov.co/index.php/catalog/819/get-microdata>

Sierra, L. F. (3 de mayo de 2024). *CENU 2024 - inicio*. Todo Lo Que Necesita Saber Sobre El Censo Económico | DANE. Recuperado de <https://censoeconomiconacionalurbano.dane.gov.co/>

de Bogotá, C. de C. (s.f). *Mercado laboral*. Org.co. Recuperado de <https://www.ccb.org.co/informacion-especializada/observatorio/analisis-economico/mercado-laboral>

RPubs - Clustering Jerárquico en R. (s/f). Rpubs.com. Recuperado de <https://rpubs.com/mjimcua/clustering-jerarquico-en-r>

(S/f). Towardsdatascience.com. Recuperado de <https://towardsdatascience.com/a-complete-guide-to-recommender-system-tutorial-with-sklearn-surprise-keras-recommender-5e52e8ceace1/>

(S/f-b). Medium.com. Recuperado de <https://medium.com/@sumanadhikari/building-a-movie-recommendation-engine-using-scikit-learn-8dbb11c5aa4b>

KMeans. (s/f). Scikit-Learn. Recuperado el 7 de abril de 2025, de <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>

Machine Learning & Clustering: el algoritmo DBSCAN. (2022, noviembre 30). Formación en ciencia de datos | DataScientest.com; DataScientest.
<https://datascientest.com/es/machine-learning-clustering-dbscan>

Chandra, R. (2024, abril 3). 9 machine learning algorithms for recommendation engines. *Daffodilsw.com*.
<https://insights.daffodilsw.com/blog/machine-learning-algorithms-for-recommendation-engines>

Kavlakoglu, E. (2025, febrero 10). ¿Qué es el filtrado basado en contenido? *IBM.com*.
<https://www.ibm.com/mx-es/think/topics/content-based-filtering>

Villalonga, R. (2017, diciembre 1). *Sistemas recomendadores híbridos*. Medium.
<https://medium.com/@rvillalongar/sistemas-recomendadores-hibridos-93a6fff29500>